```python
# Aluno: Charles Villalba

import pandas as pd
import os
import kagglehub

# Download latest version
path = kagglehub.dataset_download("thedevastator/netflix-top-rated-movies-and-tv-shows-2020-2022")
df = pd.read_csv(os.path.join(path, "raw_titles.csv"))
```

Vamos ter um preview do arquivo

```python
df.head()
```

Columns 1–8 of 14

	index	id	title	type	release_year	age_certification	runtime
0	0	ts300399	Five Came Back: The Reference Films	SHOW	1945	TV-MA	48
1	1	tm84618	Taxi Driver	MOVIE	1976	R	113
2	2	tm127384	Monty Python and the Holy Grail	MOVIE	1975	PG	91
3	3	tm70993	Life of Brian	MOVIE	1979	R	94
4	4	tm190788	The Exorcist	MOVIE	1973	R	133

Columns 9–14 of 14 · first column repeated

	genres	production_countries	seasons	imdb_id	imdb_score	imdb_votes
0	['documentation']	['US']	1.0	NaN	NaN	NaN
1	['crime', 'drama']	['US']	NaN	tt0075314	8.3	795222.0
2	['comedy', 'fantasy']	['GB']	NaN	tt0071853	8.2	530877.0
3	['comedy']	['GB']	NaN	tt0079470	8.0	392419.0
4	['horror']	['US']	NaN	tt0070047	8.1	391942.0

Agora vamos ver o quão grande é esse dataset, ou seja, a dimensão dele

```
df.shape
```

```
(5806, 13)
```

1. Identificação: Classificar as colunas do dataset em variáveis Qualitativas (Nominais/Ordinais) e Quantitativas (Discretas/Contínuas).

```
df.columns
```

```
Index(['index', 'id', 'title', 'type', 'release_year', 'age_certification',
       'runtime', 'genres', 'production_countries', 'seasons', 'imdb_id',
       'imdb_score', 'imdb_votes'],
      dtype='str')
```

```
df.dtypes
```

```
index                    int64
id                         str
title                      str
type                       str
release_year             int64
age_certification          str
runtime                  int64
genres                     str
production_countries       str
seasons                float64
imdb_id                    str
imdb_score             float64
imdb_votes             float64
dtype: object
```

Variáveis Qualitativas (Nominais/Ordinais)

Nominais: id, title, type, genres, production_countries, imdb_id. Ordinal: age_certification.

Variáveis Quantitativas (Discretas/Contínuas)

Discretas: release_year, seasons, imdb_votes. Contínuas: runtime, imdb_score.

2. Limpeza: Verificar se há valores nulos (missing values) e duplicados, e decidir o que fazer com

eles.

Verificar se existem valores nulos

```
df.isnull().sum()
```

```
index                     0
id                        0
title                     1
type                      0
release_year              0
age_certification      2610
runtime                   0
genres                    0
production_countries      0
seasons                3759
imdb_id                 444
imdb_score              523
imdb_votes              539
dtype: int64
```

Verificar duplicados

```
df.duplicated().sum()
```

```
np.int64(0)
```

O que fazer?

```
df.isnull().sum()
```

```
index                     0
id                        0
title                     1
type                      0
release_year              0
age_certification      2610
runtime                   0
genres                    0
production_countries      0
seasons                3759
imdb_id                 444
imdb_score              523
imdb_votes              539
dtype: int64
```

- Aqui podemos ver a falta de 3.759 registros sem o dado para "temporada", será que são séries sem temporadas? Vamos investigar.

```
df["type"].value_counts()
```

```
type
MOVIE    3759
SHOW     2047
Name: count, dtype: int64
```

- O número de filmes bateu com a quantidade de dados ausentes para temporada, logo, é o esperado, pois, filmes não possuem temporadas.
- Eu quero manter minha base a mais completa possível, desta forma removerei todos os dados ausentes em imdb_id, imdb_score, imdb_votes, age_certification, title.

```
df = df.dropna(subset=["title", "imdb_score", "imdb_votes", "age_certification" ])

df.isnull().sum()
```

```
index                     0
id                        0
title                     0
type                      0
release_year              0
age_certification         0
runtime                   0
genres                    0
production_countries      0
seasons                1319
imdb_id                   0
imdb_score                0
imdb_votes                0
dtype: int64
```

- Vou analizar qual a quantidade que mais se perdeu ao remover os dados nulos:

```
df["type"].value_counts()
```

```
type
SHOW     1670
MOVIE    1319
Name: count, dtype: int64
```

```
print(f'Perdemos {3759 - 1670} filmes e {2047 - 1319} séries.')
```

```
Perdemos 2089 filmes e 728 séries.
```

3. Estatística Básica: Calcular Média, Mediana, Moda e Desvio Padrão de uma coluna numérica

importante (ex: Duração do Filme, Avaliação, Preço).

- Escolherei a nota média das avaliações no imdb.
- O motivo para essa escolha é considerando que sou assinante em potencial da Netflix desejo saber se aquele serviço me fornecerá séries e filmes de qualidade, ou, se aquele acervo de mídias é minimamente agradável para a maioria das pessoas

```
media = df["imdb_score"].mean()
mediana = df["imdb_score"].median()
moda = df["imdb_score"].mode()[0]
desvio_padrao = df["imdb_score"].std()

print(f"Média: {media:.2f}")
print(f"Mediana: {mediana:.2f}")
print(f"Moda: {moda:.2f}")
print(f"Desvio padrão: {desvio_padrao:.2f}")
```

```
Média: 6.73
Mediana: 6.80
Moda: 6.80
Desvio padrão: 1.13
```

- Acima temos a média geral. Porém, eu tenho preferencia por filmes e minha esposa por séries.
- Vejamos a média baseada nas categorias.

```
movies = df[df["type"] == "MOVIE"]
shows = df[df["type"] == "SHOW"]
```

```
df.groupby("type")["imdb_score"].agg(
    media="mean",
    mediana="median",
    moda=lambda x: x.mode().iloc[0],
    desvio_padrao="std"
)
```

	media	mediana	moda	desvio_padrao
type				
MOVIE	6.349659	6.4	6.3	1.086480
SHOW	7.032335	7.2	7.6	1.070021

- Podemos ver que a Netflix investe mais na curadoria de séries sendo significativamente maior em nota do que os filmes. Notícia triste para mim.

4. Visualização: Gerar pelo menos dois gráficos simples (exemplo: 1 Gráfico de Barras para

categorias e 1 Histograma/Boxplot para distribuição numérica).

- Quero explorar aqui duas dúvidas que tenho:
  - 1. Qual a diversidade deste catálogo? Eu gosto muito de Hollywood, mas as vezes sinto falta de ver outras produções.
  - 1. Qual a média das produções baseado nos países? De nada adianta termos vários países e só os piores filmes daquela região.

```
df["production_countries"].head(10)
```

```
1     ['US']
2     ['GB']
3     ['GB']
4     ['US']
5     ['GB']
6     ['US']
7     ['US']
8     ['US']
9     ['US']
10    ['US']
Name: production_countries, dtype: str
```

```
# Preciso saber se existem multiplos países associados
df[df["production_countries"].str.contains(",")]["production_countries"].count()
```

```
np.int64(328)
```

```
# Transformarei os países em listas, assim poderemos contá-los mais facilmente.

import ast

paises = df.copy()
paises["production_countries"] = paises["production_countries"].apply(ast.literal_eval)
paises["production_countries"].head(10)
```

```
1     [US]
2     [GB]
3     [GB]
4     [US]
5     [GB]
6     [US]
7     [US]
8     [US]
9     [US]
10    [US]
Name: production_countries, dtype: object
```

```
paises = paises.explode("production_countries")
paises["production_countries"].value_counts()
```

```
production_countries
US    1499
GB     256
IN     236
JP     204
CA     122
      ...
LT       1
AL       1
MU       1
MY       1
KW       1
Name: count, Length: 75, dtype: int64
```

```
# Agora que sabemos quantas produções temos por país, vamos seprar por tipo:
paises[["production_countries", "type"]].head(10)
```

	production_countries	type
1	US	MOVIE
2	GB	MOVIE
3	GB	MOVIE
4	US	MOVIE
5	GB	SHOW
6	US	MOVIE
7	US	MOVIE
8	US	MOVIE
9	US	MOVIE
10	US	MOVIE

```
# Aqui um pouco de programação: salvei a tabela inicial numa variável, a qual realizei
uma soma do total de movie e show e por fim ordenei.
contagem_paises = paises.groupby(
    ["production_countries", "type"]
).size().unstack(fill_value=0)


contagem_paises["TOTAL"] = contagem_paises["MOVIE"] + contagem_paises["SHOW"]
contagem_paises.sort_values("TOTAL", ascending=False)
```

type	MOVIE	SHOW	TOTAL
production_countries			
US	780	719	1499
GB	134	122	256
IN	205	31	236
JP	63	141	204
CA	69	53	122
...	...	...	...
HR	0	1	1
GH	1	0	1
CY	1	0	1
BY	0	1	1
ZW	1	0	1

75 rows × 3 columns

Gráfico 1: Quantidade de mídia por país

```
top10 = contagem_paises.sort_values("TOTAL", ascending=False).head(10)

top10[["MOVIE", "SHOW"]].plot(kind="bar")
```

```
<Axes: xlabel='production_countries'>
```

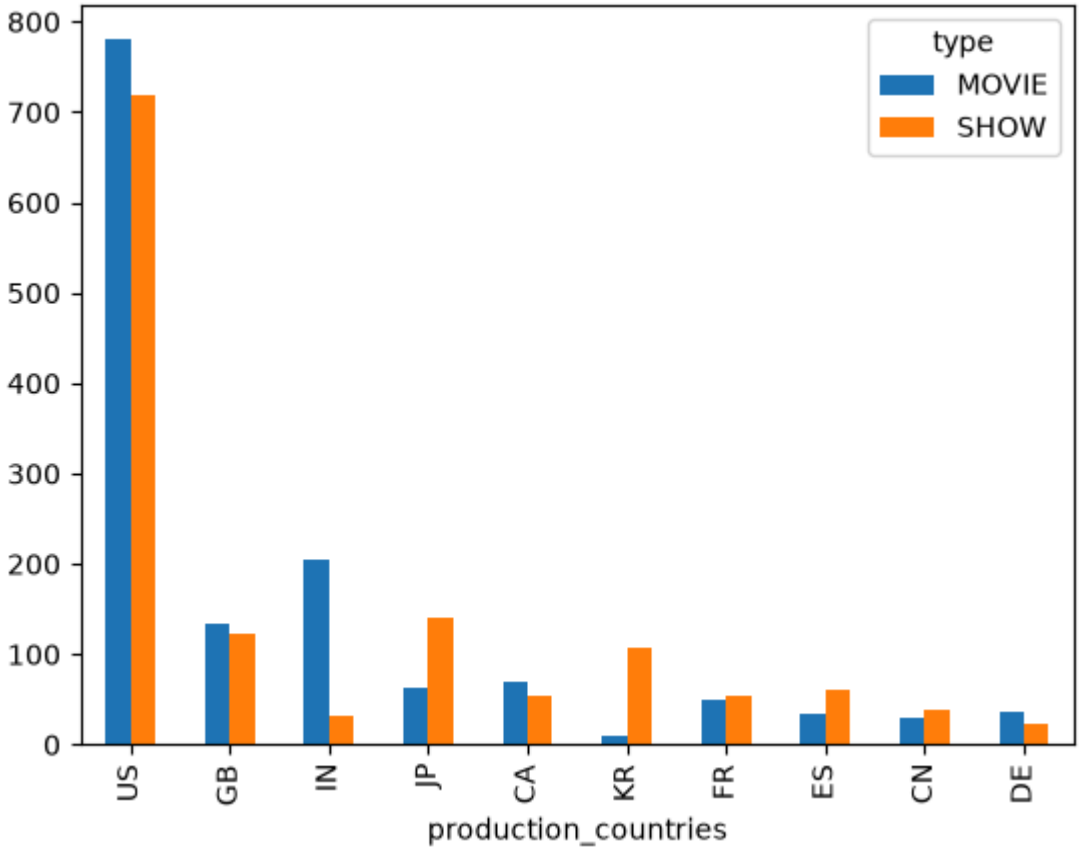


Gráfico 2: Nota média por país

```
media_por_pais = paises.groupby("production_countries")["imdb_score"].mean()

media_por_pais
```

```
production_countries
AE    5.709091
AL    6.200000
AR    6.885714
AT    7.000000
AU    6.741176
        ...
US    6.610073
VA    6.400000
XX    6.688889
ZA    6.246667
ZW    6.100000
Name: imdb_score, Length: 75, dtype: float64
```

```
media_por_pais.sort_values(ascending=False)
```

```
production_countries
GH    7.700000
IL    7.466667
HR    7.400000
KR    7.375214
PT    7.333333
        ...
SY    5.400000
RO    5.200000
KW    5.200000
LT    4.700000
CY    2.900000
Name: imdb_score, Length: 75, dtype: float64
```

```
analise_paises = paises.groupby(
    ["production_countries", "type"]
)["imdb_score"].agg(["count", "mean"])

analise_paises.sort_values("count", ascending=False)
```

		count	mean
production_countries	type		
US	MOVIE	780	6.278846
	SHOW	719	6.969402
IN	MOVIE	205	6.671220
JP	SHOW	141	7.256028
GB	MOVIE	134	6.538806
...	...	...	...
PT	MOVIE	1	6.600000
RS	MOVIE	1	6.400000
MA	MOVIE	1	5.500000
SA	MOVIE	1	5.900000
ZW	MOVIE	1	6.100000

125 rows × 2 columns

```
top10.index
```

```
Index(['US', 'GB', 'IN', 'JP', 'CA', 'KR', 'FR', 'ES', 'CN', 'DE'], dtype='str',
name='production_countries')
```

```
# Agora podemos ter uma visão melhor de quais países mais possuem produção e suas respectivas notas médias em cada tipo

analise_top10 = analise_paises.loc[top10.index]
analise_top10
```

		count	mean
production_countries	type		
US	MOVIE	780	6.278846
	SHOW	719	6.969402
GB	MOVIE	134	6.538806
	SHOW	122	7.195902
IN	MOVIE	205	6.671220
	SHOW	31	6.977419
JP	MOVIE	63	6.769841
	SHOW	141	7.256028
CA	MOVIE	69	6.065217
	SHOW	53	7.043396
KR	MOVIE	9	6.511111
	SHOW	108	7.447222
FR	MOVIE	50	6.360000
	SHOW	53	6.958491
ES	MOVIE	35	6.500000
	SHOW	61	6.724590
CN	MOVIE	30	6.333333
	SHOW	38	7.457895
DE	MOVIE	37	6.462162
	SHOW	22	7.240909

```python
import matplotlib.pyplot as plt

plt.figure(figsize=(10, 6))

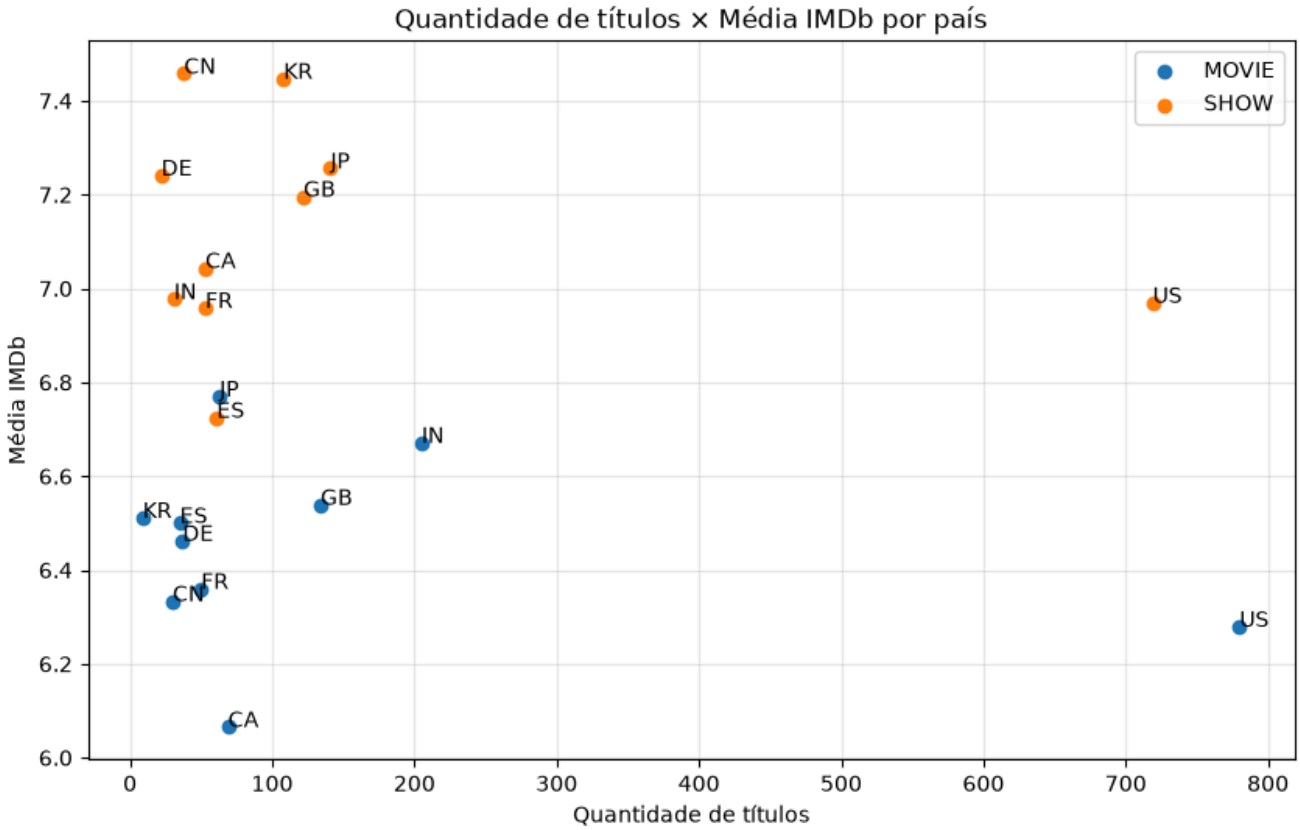
for tipo in ["MOVIE", "SHOW"]:
    dados = analise_top10.xs(tipo, level="type")

    plt.scatter(
        dados["count"],
        dados["mean"],
        label=tipo
    )

    # Identifica cada ponto pelo país
    for pais, linha in dados.iterrows():
        plt.annotate(
            pais,
            (linha["count"], linha["mean"])
        )

plt.title("Quantidade de títulos × Média IMDb por país")
plt.xlabel("Quantidade de títulos")
plt.ylabel("Média IMDb")
plt.legend()
plt.grid(True, alpha=0.3)

plt.show()
```



5. Conclusão: Escrever 2 insights simples baseados nas análises realizadas.

A partir das análises, podemos concluir que:

1. O catálogo da Netflix realmente possui uma curadoria que preza a qualidade e diversidade. Entretanto, existe uma clara preferência por séries de melhor qualidade à filmes de melhor qualidade.
2. Apesar da maior quantidade de produções norte-americanas, quase todos as séries e filmes de outros países possuem notas melhores que as produções norte-americanas.