Aluno: Charles Balmant Villalba
Matrícula: A2951843
Matéria: Introdução a Ciência de Dados

Atividade Prática 02 - Aumento da Base de Dados

Quando aumentamos o conjunto de dados de 500 para 1000 amostras, o desempenho aumenta ou diminui? Você viu em sala que o desempenho diminui, a pergunta é: por quê?

O churn é o termo dado a ação dos clientes de uma empresa cancelar um serviço ou deixarem de usar um produto. Utilizando dados como tempo de contrato, frequência de uso ou compra, valores pagos, histórico de relacionamento (por exemplo, pedidos de suporte) podemos tentar agrupar os clientes em quais possuem mais chances de churn ou não por meio de algoritmos de árvore de decisão.

Para treinar modelos, utilizamos dados e em geral, espera-se que o aumento da quantidade de dados utilizados no treinamento melhore o desempenho de um modelo, uma vez que, ele passará a ter mais exemplos para identificar padrões. Entretanto, durante as aulas vimos que o aumento do conjunto de dados de 500 para 1000 amostras não duplicou o desempenho do modelo. Embora possa ser contraintuitivo, é completamente plausível tendo como causa raiz inúmeras explicações.

Uma possível explicação pode estar relacionada ao que chamamos de “sobreajuste" (ou overfitting). As árvores de decisão podem criar regras muito específicas para os dados de treinamento, considerando padrões ocasionais e/ou informações que não representam o comportamento geral dos clientes. Quando novos casos são adicionados, essas regras podem deixar de funcionar da forma esperada e prejudicar a capacidade de gerenalização do modelo.

Outra possível explicação é a quantidade e a distribuição dos dados. Com o aumento de 500 amostras no modelo, também podemos ter introduzido 500 novos comportamentos, o que acaba trazendo variabilidade para o que o modelo já conhecida, que pode acarretar em comportamentos mais difíceis para classificação. Portanto, a depender da distribuição dessas amostras, poderemos ter desequilíbrio e prejudicarmos o aprendizado do modelo.

Também precisamos considerar como ocorre a forma de avaliação do modelo. Caso os casos de teste e treinamento tenham sido gerados aleatoriamente, a diferença de desempenho pode estar relacionada a composição destes dados. Assim, uma redução de acurácia não significa necessariamente que o aumento de dados poderá sempre trazer malefícios.

Portanto, aumentar o volume de dados não garante, por si só, uma melhoria imediata no desempenho. No experimento, a queda observada pode estar associada ao sobreajuste, à presença de ruídos, ao desequilíbrio entre classes ou às diferenças entre os conjuntos de avaliação. Para chegarmos a uma conclusão sobre a causa, precisaríamos investigar com técnicas de validação e avaliar os dados utilizados, realizando primariamente algum nível de tratamento.

Referência bibliográfica:

SCIKIT-LEARN DEVELOPERS. Decision Trees. Scikit-learn: Machine Learning in Python, [s. d.]. Disponível em: https://scikit-learn.org/stable/modules/tree.html. Acesso em: 21 out. 2026.

SCIKIT-LEARN DEVELOPERS. Learning Curves. Scikit-learn: Machine Learning in Python, [s. d.]. Disponível em: https://scikit-learn.org/stable/modules/learning_curve.html. Acesso em: 21 out. 2026.